Image Classification & Object Detection

水果影像辨識系統

從白底資料集到真實照片：分類（A）＋偵測（B）的訓練、測試與整合

PyTorch | ResNet18 | MobileNetV2 | YOLOv8s | Gradio

陳姵圻 Pei-Chi Chen





圖片： Unsplash 攝影師（LuAnn Hunt 、 Mekht）；框圖為本專題模型輸出

研究動機

白底資料集的高分，到了真實照片會剩多少?

Q1

落差有多大

分類模型在白底圖與真實照片上的準確率差多少?

Q2

和文獻比如何

資料集成績與文獻接近嗎? 真實照片還能維持嗎?

Q3

A 、 B 能否互補

分類（判斷種類）與偵測（框出數量）各自擅長什麼?

公開水果資料集多半是白底、單顆水果；實際照片裡的水果會堆疊、被遮住、背景複雜。本專題訓練 A 分類與 B 偵測兩種模型，並用真實照片與圖庫照片檢查落差。

專題流程

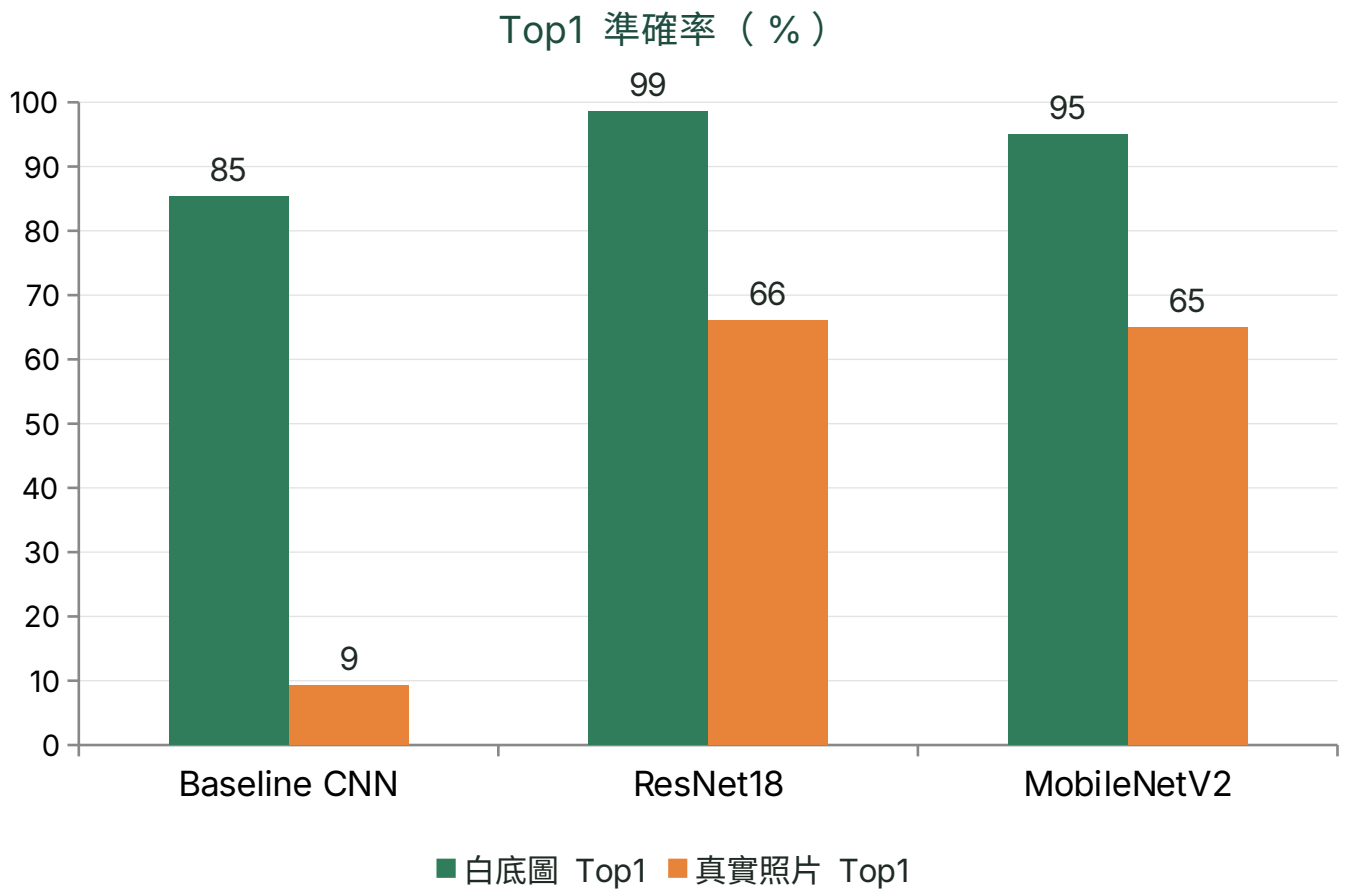
兩條模型線，最後整合進同一個介面

	資料	模型	訓練	評估
A 分類	Fruits-360 （55 個水果大類）	ResNet18 ／ MobileNetV2 ／ Baseline CNN	先白底 15 epoch，再加入真實照片 10 epoch	白底 5,000 張＋ real_test109
B 偵測	Zenodo 水果偵測資料集（YOLO 格式）	YOLOv8s， 50 epoch、 640 px、批次 16	舊 30 類 → 補 5 類 → 新 26 類	資料集 test ＋ 189 張真實／圖庫照片

整合： Gradio 介面

上傳照片 → A 判斷種類、 B 框出位置與數量；一般模式（固定 R0 ）與研究模式（參數可調、 R0 ～ R9 可重現）

A 分類：加入真實照片後，才有真實場景的辨識能力



15.5% → 66.0%

ResNet18 真實照片 Top1：只用白底圖 → 加入真實照片

19.6% → 64.9%

MobileNetV2 同樣的比較

兩個遷移學習模型在真實照片約 65%，ResNet18 與 MobileNetV2 差距不顯著（97 張，95% 信賴區間約 55–75%）。Baseline CNN 從零訓練，真實照片只剩 9.3%。

資料：real_test109 單一水果 97 張；白底為 Fruits-360 original-size 測試集抽樣 5,000 張。

B 偵測： YOLOv8s 升級為 26 類，資料集成績全面提升

0.772

Test mAP@0.5

0.501

Test mAP@0.5:0.95

74.0%

Precision

75.9%

Recall

指標	舊 B （30 類）	新 B （26 類）	文獻 YOLOv12l
Precision	0.677	**0.740**	0.762
Recall	0.696	**0.759**	0.679
mAP@0.5	0.714	**0.772**	0.717
mAP@0.5:0.95	0.431	**0.501**	0.445

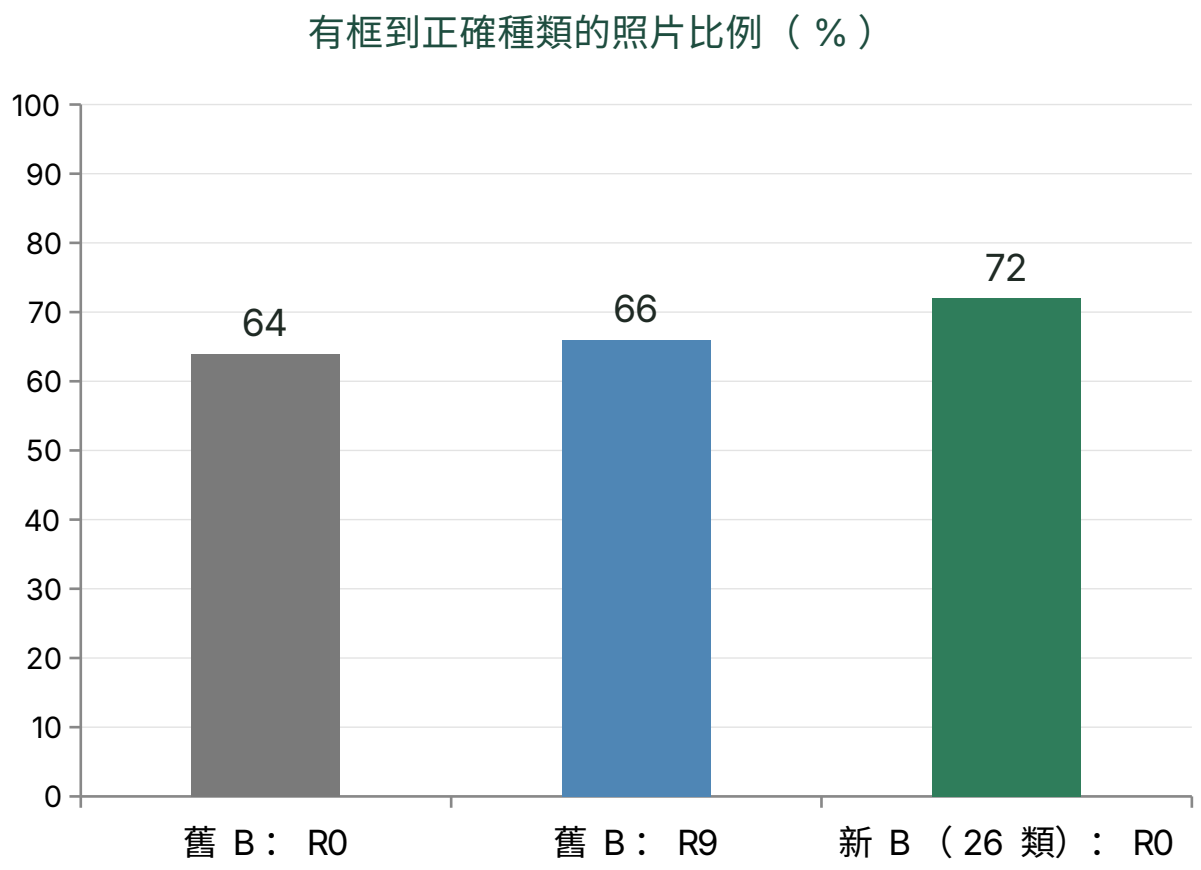
新增奇異果、覆盆子、黑莓、哈密瓜、菠蘿蜜；拿掉 9 類蔬菜。新增類別訓練原圖僅 15–104 張，以重複放入補量。

不能直接說「變準了」：新舊測試組不同（1,685 張 → 1,482 張），且拿掉的蔬菜類別 AP50 原本偏低，平均會被拉高。

資料： Colab_B_fruit26_fixed.ipynb （best.pt， 640 px）；舊 B 與文獻數字見 v12 簡報。條件不同，只對照趨勢。

真實照片測試（範圍內 150 張）

真實與圖庫照片：框到正確種類的比例 64% → 72%



新增 5 類（24 張）	舊 R0	新 B
奇異果	0/4	**4/4**
哈密瓜	0/3	**3/3**
黑莓	0/8	3/8
覆盆子	0/6	3/6
菠蘿蜜	0/3	0/3
合計	**0/24**	**13/24**

「有框到」＝至少框到 1 個種類正確的框，不看數量與多框。 real_test109 為 Fruits-360 multi 照片， stock_test_set 為 Unsplash ／ Pexels 手選照片，不代表一般情況。

資料： 189 張逐張清單（範圍內 150 張＝ real 86 ＋ stock 64 ）；判定由程式依正確答案計算。

取捨與誠實揭露

框得更多，錯誤框也變多：這是補類別的代價

範圍內 150 張	舊 R0	新 B
總框數	1,492	2,061
正確框	852	**1,127**
錯誤框	640	**934**
框對率	57.1%	54.7%
完全沒框的照片	12 張	**5 張**

逐張比較：改善 38、沒變 63、更差 49 張；更差中只有 2 張是少框到正確種類，其餘 47 張是錯誤框變多。

新增類別的誤框

146 個誤框、分布在 25 張照片；覆盆子最多（102），多出現在紅色的草莓堆與荔枝堆。原資料集草莓只有 83 個框。

是否值得，要看應用場景能不能接受錯誤框。因此研究模式讓使用者自己調整信心門檻，一般模式不做過度修補。

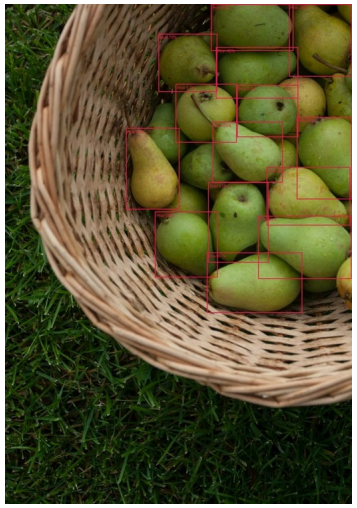
驗收三項標準（原 21 類正確框不減、新增類別有被框到、香蕉桃子不退步）皆達標； R9 尚未在新 B 上測。

整合分析

A 、 B 互補：各有看不到的地方



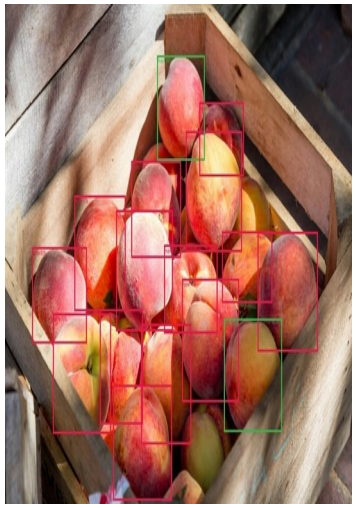
蘋果： A 對、 B 對



梨子： A 判成蘋果、 B 框到 14 顆梨子



香蕉： A 90–100% 、 B 沒偵測到



桃子： A 對、 B 框成蘋果

單一水果 176 張	舊 B	新 B
A 、 B 都對	60	73
只有 B 對	28	38
只有 A 對	37	24
都沒對	51	41
至少一個對	125 （71.0%）	**135 （76.7%）**

A 回答「是什麼水果」， B 回答「在哪裡、有幾顆」。換成新 B 後，至少一個答對的比例上升， B 補 A 的比例變大。

四個例子用來說明互補，不代表整體比例。圖片： Unsplash 攝影師 Marek Studzinski 、 Mekht 、 Gabriel Mihalcea 、 LuAnn Hunt ；框圖為本專題模型輸出。

實驗設計與結果

R0 ～ R9： 用實驗決定哪些設定能進一般模式

輪次	改了什麼	21 類內 改善／沒變／更差	結論
R0	基準：信心 0.35 、重疊 0.5 、 640 px	—	**一般模式預設**
R1	信心 0.25	4 ／ 11 ／ 5	只救回少數；用於「完全沒框到」時自動重試
R3	信心 0.25 ＋ 960 px	9 ／ 6 ／ 5	救回最多，但常框成錯誤種類
R5	A 全部重新命名	25 ／ 25 ／ 15	B 的框常被改成錯誤種類
R7	A 重新命名並刪除 A 認不出的框	57 ／ 27 ／ 66	沒問題的 85 張有 54 張變差
R8	A 有把握才改名	16 ／ 103 ／ 31	沒問題的 85 張有 27 張變差
R9	只補 B 沒有的名稱； B 原有的要 A≥0.9 才改	9 ／ 133 ／ 8	**最保守，但仍改壞少數、速度較慢 → 研究模式**

R2 、 R4 、 R6 幾乎沒幫助，另有 2×2 分塊辨識只幫得到 B 原本認得的水果；皆保留在 GitHub 實驗紀錄，不放進介面快捷選項。

各輪跑的張數不同（R1 、 R3 、 R5 只重跑原本有問題的照片； R7 ～ R9 跑全部），數字為 v12 簡報第 35 頁。

介面設計

一般模式簡單可用，研究模式可重現每一輪實驗

一般模式（預設）

- 只有「上傳照片」與「辨識」
- 固定 R0：信心 0.35、重疊 0.5、640 px
- 完全沒框到時，自動以信心 0.25 重試並提示較不確定
- 仍沒框到，顯示 A 的第一名判斷

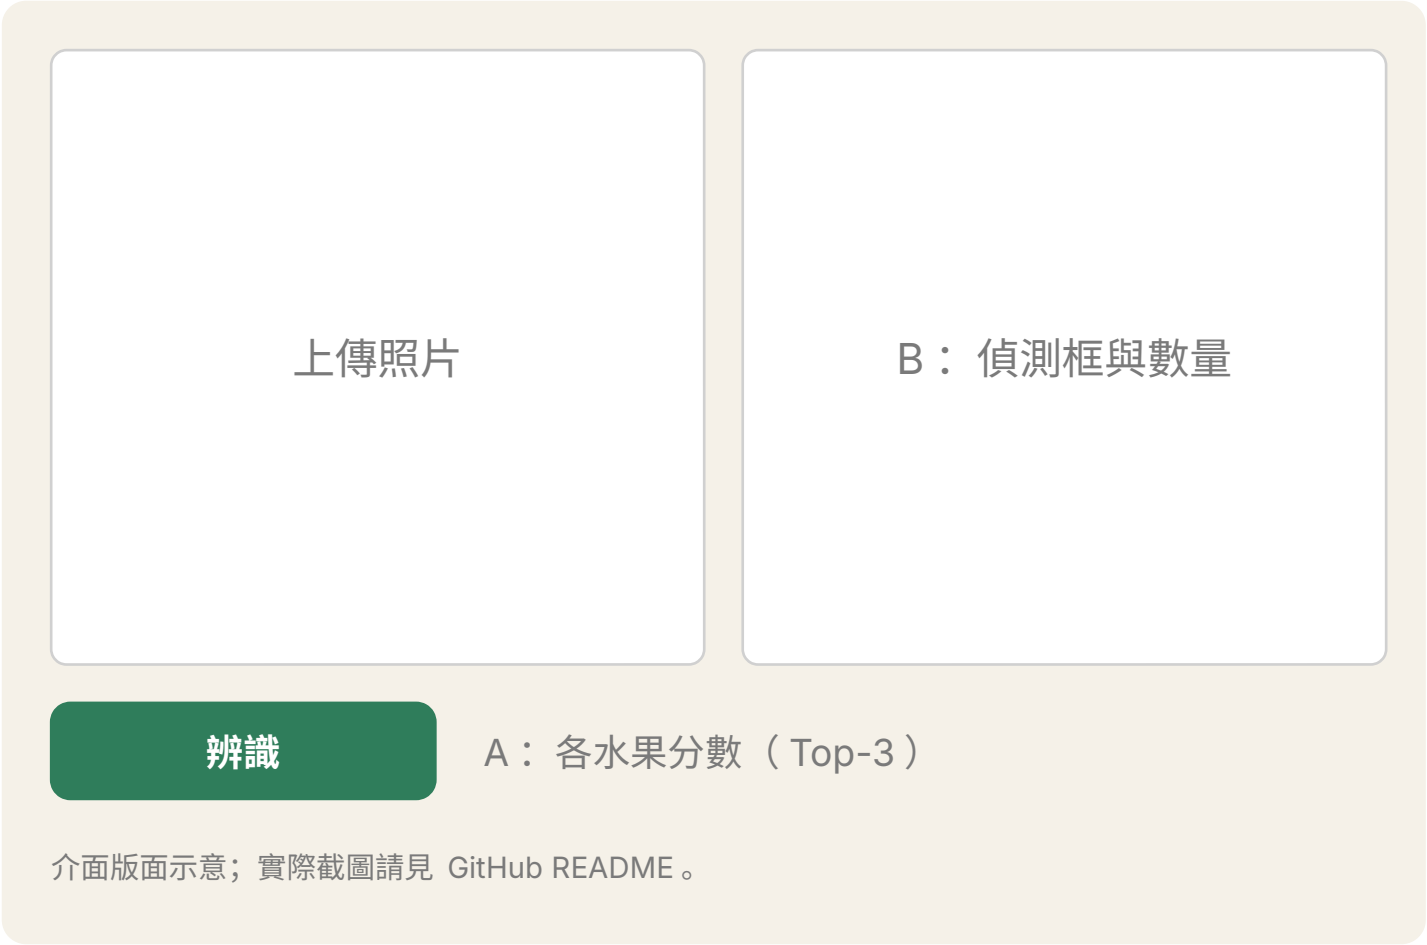
研究模式（進階設定）

- 信心、重疊、圖片大小可調
- A 輔助重新命名（關閉／R9）
- 自動分塊（2×2）
- 一鍵套用 R0、R1、R3、R9；手動調整則標示為「自訂」
- 自動重試關閉，結果可與 R0 ～ R9 逐張比較

R9 預設關閉：它會改壞少數原本正確的結果、每個框多跑一次 A，速度較慢。

系統展示

Gradio 系統與線上 Demo



線上 Demo

Hugging Face Spaces （Gradio）
huggingface.co/spaces/< 帳號 >/fruit-recognition

原始碼與實驗紀錄

GitHub
github.com/< 帳號 >/Fruit-Recognition

提醒：免費 CPU 上處理時間約 15 秒； 960 px 與分塊更慢，建議先試範例圖。

結論與後續改善

- 白底高分不等於真實可用： A 從 95–98% 掉到 65–66%；加入真實照片是必要的。
- B 升級為 26 類後，資料集 mAP@0.5 達 0.772，真實與圖庫照片框到正確種類 64% → 72%；代價是錯誤框 640 → 934。
- A、B 互補：至少一個答對 71.0% → 76.7%。 R9 保守但有代價，所以只放研究模式。

後續

- 補黑莓、桃子、梨子的真實照片，重新訓練 A
- 補油桃、龍眼等類別；修正資料組重複照片；抽查新 B 的覆盆子誤框
- 把 R9 相近類別對應回 B 的類別，減少改壞的結果

資料來源與授權： Fruits-360 （CC BY-SA 4.0）、 Zenodo 18904638 （CC BY 4.0）、 Unsplash ／ Pexels 圖庫照片，詳見 README。